

TOURISM ARRIVALS FORECASTING TECHNIQUES

MAI 2026

ABDELLAH NAIT AKLI
YASSIR MOTIA
FABIAN ZETU
LOIC WAGALE

1. Introduction

Le secteur du tourisme, par sa nature cyclique et sa sensibilité aux facteurs exogènes, représente un terrain d'application particulièrement pertinent pour les méthodes de prévision de séries temporelles. La capacité à anticiper les flux touristiques avec précision constitue un levier stratégique majeur pour les acteurs publics comme privés, que ce soit en matière de dimensionnement des infrastructures, d'allocation des ressources ou de pilotage de la performance.

Dans ce contexte, le présent projet propose une analyse approfondie de l'évolution mensuelle du nombre de touristes (en millions) sur la période février 2016 – mai 2025, soit un historique de 112 observations. Ce jeu de données, par sa profondeur temporelle, offre un cadre propice à l'identification des dynamiques structurelles (tendance de fond, saisonnalité, ruptures éventuelles) et à la mise en concurrence de plusieurs approches de modélisation.

Notre démarche s'inscrit dans une logique de benchmark méthodologique structurée en trois temps. 1) Nous procédons d'abord à une exploration rigoureuse des données afin d'en caractériser les propriétés statistiques et d'orienter les choix de modélisation, ensuite 2) nous déployons un éventail de méthodes couvrant le spectre des approches classiques (décomposition, lissage exponentiel, modèles ARIMA/SARIMA) et des approches plus récentes (Prophet, bootstrap sur séries temporelles). 3) Enfin, nous comparons les performances prédictives de chaque modèle sur la base de métriques objectives, dans une optique de sélection du modèle le plus adapté au cas d'usage.

L'ensemble de l'analyse est conduit sous Python, garantissant reproductibilité et scalabilité de la démarche.

1. Analyse du dataset

Quelques statistiques descriptives

Tout d'abord, on commence par quelques statistiques descriptives de notre base de données.

TABLE 1 – Statistiques descriptives de la série brute.

Indicateur	Valeur
Période	Fév. 2016 – Mai 2025
Nombre d'observations	112
Minimum	0,01 M (août 2020)
Maximum	2,38 M (janv. 2025)
Moyenne globale	1,29 M
Moyenne pré-COVID (2016–2019)	1,70 M
Moyenne post-COVID (avr. 2022–mai 2025)	1,42 M

Analyse graphique

On passe ensuite à la représentation graphique de notre série temporelle pour pouvoir identifier s'il y a une présence de saisonnalités ou de tendances.




FIGURE 1 – Arrivées mensuelles brutes sur la période fév. 2016 – mai 2025

Sur la période pré-pandémique de février 2016 à février 2020, la série évolue autour d'un niveau moyen relativement stable, entre 1.3 et 2.3 millions d'arrivées mensuelles, avec une saisonnalité annuelle marquée par des pics estivaux, et des creux hivernaux. L'amplitude des fluctuations saisonnières semble croître avec le niveau de la série, ce qui suggère une structure multiplicative de la composante saisonnière.

Ensuite, on peut observer le choc COVID-19 qui constitue une rupture structurelle majeure. À partir de mars 2020, les arrivées s'effondrent quasi instantanément vers des niveaux proches de zéro, minimum à 0.01 million, et restent à des niveaux historiquement bas pendant près de deux ans. Sur cette fenêtre, la dynamique observée ne reflète plus les fondamentaux du secteur mais un régime exceptionnel dicté par les restrictions sanitaires.

La reprise, amorcée courant 2022, se caractérise par un retour progressif vers les niveaux pré-crise. À partir de mi-2023, la série retrouve une amplitude et une saisonnalité comparables à celles d'avant 2020. Ce constat pose la question du traitement de la période COVID dans la modélisation : l'inclure risque de biaiser les estimations des composantes tendancielle et saisonnière, tandis que l'exclure réduit la profondeur de l'historique exploitable. C'est exactement à ça que répondent les modèles qu'on va étudier par la suite.

L'Autocorrélogramme

On sait qu'en analyse des séries temporelles, après l'étude graphique, il convient d'analyser l'autocorrélogramme de notre série.




FIGURE 2 – Autocorrélogramme de la série brute, calculés sur 48 retards.

L'autocorrélogramme calculé sur la série brute complète révèle une décroissance lente des autocorrélations aux premiers retards, caractéristique d'une série non stationnaire. Cependant, les pics saisonniers que l'on attendrait aux lags multiples de 12 pour une série touristique ne ressortent pas de la bande de confiance de manière significative. Ce brouillage du signal saisonnier est imputable au choc COVID-19 : deux années de valeurs proches de zéro au cœur de l'échantillon perturbent la structure d'autocorrélation et empêchent le corrélogramme de restituer fidèlement les dynamiques récurrentes de la série.

Ce résultat illustre une limite bien connue des outils d'analyse globale en présence de ruptures structurelles : le corrélogramme, par construction, agrège l'information sur l'ensemble de l'échantillon et ne distingue pas les régimes sous-jacents. Pour dépasser cette limite et retrouver les composantes fondamentales de la série, c'est à dire tendance, saisonnalité, irrégularités, il convient alors de recourir aux méthodes de décomposition, qui offrent un cadre adapté pour isoler chaque composante et traiter explicitement la perturbation pandémique.

Saisonnalité

Avant de recourir aux méthodes de décomposition, nous cherchons à caractériser visuellement la saisonnalité de la série à travers deux représentations complémentaires : un seasonal plot, qui superpose les profils annuels pour en apprécier la récurrence, et des boxplots mensuels, qui permettent d'identifier les mois structurellement hauts et bas ainsi que la variabilité intra-mois.




FIGURE 3 – Seasonal plot (gauche) et boxplots mensuels hors COVID (droite).

Le seasonal plot confirme une saisonnalité annuelle stable : les arrivées culminent en période estivale ,donc de juillet à octobre, et atteignent leurs niveaux les plus bas en début d’année. Les années 2020-2021 rompent nettement avec ce schéma, tandis que les années post-crise retrouvent un profil comparable à celui d’avant la pandémie. Les boxplots mensuels, hors COVID, corroborent cette lecture et révèlent une dispersion intra-mois plus importante pour les mois à forte fréquentation, ce qui suggère un schéma de saisonnalité multiplicatif.

2. Les méthodes de décomposition

L’analyse préliminaire a mis en évidence une saisonnalité annuelle stable mais insuffisamment captée par le corrélogramme en raison du choc COVID-19. Le seasonal plot et les boxplots mensuels ont par ailleurs suggéré un schéma de saisonnalité multiplicatif. Pour confirmer ces observations et isoler formellement chaque composante de la série, nous appliquons les méthodes de décomposition classique — additive et multiplicative — d’abord sur la série brute, puis sur une version interpolée neutralisant la perturbation pandémique.

Méthodologie

Les méthodes de décomposition reposent sur l’hypothèse qu’une série temporelle Y_t résulte de la combinaison de composantes non directement observables : une tendance T_t , une saisonnalité S_t et un résidu R_t . Leur identification séparée poursuit un double objectif : d’une part, caractériser la dynamique structurelle de la série indépendamment des fluctuations cycliques ; d’autre part, désaisonnaliser la série afin de fournir un signal épuré sur lequel les modèles de prévision peuvent être estimés avec davantage de robustesse.

Deux schémas sont envisageables selon la nature de la relation entre l’amplitude saisonnière et le niveau de la série. Un schéma additif adapté lorsque l’amplitude saisonnière est constante en valeur absolue :

$$Y_t = T_t + S_t + R_t \quad (1)$$

et un schéma multiplicatif rivélé lorsque l'amplitude saisonnière évolue proportionnellement au niveau de la série :

$$Y_t = T_t \times S_t \times R_t \quad (2)$$

Dans les deux cas, la tendance est estimée par moyenne mobile centrée d'ordre m (avec $m = 12$ pour des données mensuelles), et les coefficients saisonniers sont obtenus par la moyenne des rapports (multiplicatif) ou des écarts (additif) entre la série observée et la tendance estimée.

Application sur la base brute




FIGURE 4 – Une décomposition additive et multiplicative appliquées sur la série brute.

La Figure 4 présente les résultats des décompositions additive et multiplicative appliquées directement sur la série brute. Dans les deux cas, la composante tendancielle capte l'effondrement lié au COVID-19 sous la forme d'un creux prononcé entre 2020 et 2022. Cependant, les résidus révèlent des valeurs extrêmes concentrées sur cette même période, signe que la rupture pandémique excède ce que le modèle de décomposition est en mesure d'absorber à travers la seule composante tendancielle. Ce constat suggère que les données de la période COVID perturbent significativement l'estimation des composantes structurelles de la série. Afin d'obtenir une décomposition exploitable, nous procédons dans l'étape suivante à une interpolation linéaire des

observations comprises entre mars 2020 et juin 2022, avant de réappliquer les deux méthodes de décomposition sur cette série corrigée.

3. Traitement de la rupture COVID-19

La décomposition appliquée sur la série brute a révélé les limites des méthodes classiques face à un choc exogène de l'ampleur de la crise sanitaire, les résidus concentrent des valeurs extrêmes sur la période 2020–2022, signe que la rupture pandémique excède ce que le modèle de décomposition est en mesure d'absorber. Les valeurs proches de zéro enregistrées pendant près de deux ans ne reflètent plus les fondamentaux du secteur touristique mais un régime exceptionnel dicté par les restrictions sanitaires. Or, les méthodes classiques de prévision, c'est à dire, lissage exponentiel, SARIMA, ne gèrent pas nativement ce type d'événements extrêmes. Si la rupture n'est pas traitée en amont, elle faussera l'estimation de la tendance de fond et de la saisonnalité, et par conséquent la qualité des prévisions.

Interpolation linéaire temporelle

Afin de neutraliser l'effet de la discontinuité pandémique sans réduire la profondeur de l'échantillon, les 25 observations comprises entre mars 2020 et mars 2022 sont substituées par une trajectoire interpolée linéairement entre le dernier point pré-crise et le premier point post-crise :

$$\hat{y}_t = y_{t_0} + \frac{y_{t_1} - y_{t_0}}{t_1 - t_0} \cdot (t - t_0), \quad t \in [t_0, t_1] \quad (3)$$

avec t_0 = février 2020 et t_1 = avril 2022. Ce choix repose sur un principe de parcimonie, en l'absence d'information fiable sur la trajectoire contrefactuelle qu'aurait suivie l'activité hors crise, l'hypothèse d'une évolution linéaire entre les deux bornes constitue l'approximation la plus neutre. Elle permet de restituer aux modèles de prévision une série exempte de rupture structurelle, tout en préservant l'intégralité de l'historique long de 112 observations.

Décomposition de la série traitée par interpolation linéaire




FIGURE 5 – Décomposition additive et multiplicative appliquées sur la série interpolée

La figure 5 présente les décompositions additive et multiplicative de la série interpolée. La comparaison avec la figure 4 confirme l’apport du traitement, c’est à dire, la composante tendancielle ne s’effondre plus vers zéro mais décrit un creux atténué avec un point bas d’environ 0,8 million, le profil saisonnier retrouve une régularité stable sur l’ensemble de la période, et l’amplitude des résidus additifs est réduite de moitié, de $\pm 0,3$ contre $\pm 0,6$ sur la série brute. Une concentration résiduelle subsiste au voisinage d’avril 2022, point de raccord entre la trajectoire interpolée et les données observées, un effet mécanique attendu et localisé.

Le modèle multiplicatif amplifie en revanche ce phénomène de raccord, la division par une tendance basse d’environ 0,8 transforme de faibles écarts absolus en déviations relatives marquées. Ce constat, conjugué à l’absence de saisonnalité proportionnelle au niveau de la série, conduit à retenir donc le schéma additif pour la suite de l’analyse.

4. Tests de stationnarité

Préalablement à toute modélisation, il convient d’abord de déterminer l’ordre d’intégration de la série. Les modèles ARIMA n’étant définis que sur des processus stationnaires, cette étape conditionne le choix des ordres de différenciation d et D qui alimenteront l’identification du modèle. Deux tests complémentaires sont mobilisés ici, le test ADF, dont l’hypothèse nulle postule la présence d’une racine unitaire, et le test KPSS, dont l’hypothèse nulle postule au contraire la stationnarité de la série.

Test	Série	Statistique	p -value	Conclusion
ADF	Y_t (niveaux)	-2,701	0,074	Non-rejet H_0 (racine unitaire)
KPSS	Y_t (niveaux)	0,362	0,094	Non-rejet H_0 (stationnarité)
ADF	ΔY_t	-1,716	0,423	Non-rejet H_0
KPSS	ΔY_t	0,096	0,100	Non-rejet H_0 (stationnarité)

TABLE 2 – Tests de stationnarité appliqués à la série interpolée en niveaux et en différence première.

Sur la série en niveaux, le test ADF ne rejette pas l’hypothèse de racine unitaire ($p = 0,074$), confirmant le caractère non stationnaire de Y_t et la nécessité d’une différenciation. Après différenciation simple, le test KPSS valide la stationnarité de ΔY_t ($p \geq 0,10$), ce qui fixe $d = 1$.

5. Modèles de prévision

La série interpolée est scindée en un échantillon d’estimation de 88 observations (février 2016 – mai 2023) et un échantillon de test de 24 observations (juin 2023 – mai 2025). La capacité prédictive des modèles est évaluée au moyen de deux métriques complémentaires : le RMSE, sensible aux erreurs de grande amplitude, et le MAPE, qui fournit une mesure relative directement interprétable.

Lissage exponentiel de Holt-Winters

Le premier cadre de modélisation retenu est le lissage exponentiel triple de Holt-Winters, qui prolonge naturellement l’analyse de décomposition en estimant conjointement niveau, tendance et saisonnalité par mise à jour récursive.

Méthode additive

Le lissage exponentiel triple additif met à jour récursivement trois composantes :

$$\ell_t = \alpha (Y_t - s_{t-m}) + (1 - \alpha) (\ell_{t-1} + T_{t-1}) \quad (4)$$

$$T_t = \beta (\ell_t - \ell_{t-1}) + (1 - \beta) T_{t-1} \quad (5)$$

$$s_t = \gamma (Y_t - \ell_t) + (1 - \gamma) s_{t-m} \quad (6)$$

$$\hat{Y}_{t+h|t} = \ell_t + T_t \cdot h + s_{t-m+h_m} \quad (7)$$

La composante saisonnière, exprimée en termes absolus, est retranchée de la série pour en extraire le niveau désaisonnalisé.

Méthode multiplicative

Dans la variante multiplicative, la saisonnalité intervient sous forme de ratio :

$$\ell_t = \alpha \frac{Y_t}{s_{t-m}} + (1 - \alpha) (\ell_{t-1} + T_{t-1}) \quad (8)$$

$$T_t = \beta (\ell_t - \ell_{t-1}) + (1 - \beta) T_{t-1} \quad (9)$$

$$s_t = \gamma \frac{Y_t}{\ell_t + T_{t-1}} + (1 - \gamma) s_{t-m} \quad (10)$$

$$\hat{Y}_{t+h|t} = (\ell_t + T_t \cdot h) \times s_{t-m+h_m} \quad (11)$$

Ce schéma est adapté aux séries dont l'amplitude saisonnière croît proportionnellement au niveau ; il est en revanche contre-indiqué lorsque cette amplitude demeure stable — précisément le cas identifié lors de la décomposition.

Comparaison et choix

Variante	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\gamma}$	RMSE	MAPE
Additif	0,5563	0,1899	0,3587	0,208	9,8 %
Multiplicatif	0,5397	0,2930	0,0000	0,439	21,0 %

TABLE 3 – Paramètres estimés et performances hors-échantillon des deux variantes de Holt-Winters.




FIGURE 6 – Comparaison Holt-Winters additif et multiplicatif sur la période de test.

La supériorité du schéma additif est sans ambiguïté (MAPE 9,8 % contre 21,0 %). L'examen des paramètres éclaire ce résultat : le modèle additif affiche un $\hat{\gamma} = 0,36$, signe d'une mise à jour effective des coefficients saisonniers, tandis que le multiplicatif produit $\hat{\gamma} = 0$, indiquant que l'algorithme n'a jamais jugé nécessaire de réviser la saisonnalité — un symptôme d'inadéquation structurelle. Ce constat confirme le diagnostic de la section 3 : l'amplitude saisonnière de la série est approximativement constante, rendant le schéma multiplicatif inadapté. Le modèle additif est retenu pour la suite.

Modèle SARIMA

Le lissage exponentiel capte efficacement le profil saisonnier mais ne modélise pas explicitement la structure d'autocorrélation de la série. Pour exploiter cette information, on se tourne vers le cadre SARIMA de Box-Jenkins. Les tests de stationnarité (section 4) ayant établi $d = 1$, et la persistance des corrélations aux décalages multiples de 12 motivant $D = 1$, l'identification porte sur les ordres (p, q) et (P, Q) .

Sélection de l'ordre

Un balayage exhaustif sur la grille $(p, q) \in \{0, 1, 2\}^2$, $(P, Q) \in \{0, 1\}^2$ avec $(d, D) = (1, 1)$ est conduit, soit 36 spécifications.

Modèle	AIC	BIC	MAPE test
SARIMA(2, 1, 2)(0, 1, 0) ₁₂	−75,49	−64,11	31,4 %
SARIMA(2, 1, 1)(0, 1, 0) ₁₂	−75,36	−66,20	30,7 %
SARIMA(1, 1, 0)(0, 1, 0) ₁₂	−72,24	−67,63	28,9 %
SARIMA(0, 1, 1)(0, 1, 0) ₁₂	−71,58	−67,00	29,2 %
...			
SARIMA(0, 1, 2)(1, 1, 1)₁₂	−46,18		3,4 %

TABLE 4 – Sélection SARIMA : meilleures spécifications par AIC et modèle retenu (dernière ligne).

Les spécifications les mieux classées par AIC partagent la partie saisonnière $(0, 1, 0)_{12}$ et affichent des MAPE de l'ordre de 29–31 %. Le SARIMA(0, 1, 2)(1, 1, 1)₁₂, en dépit d'un AIC sensiblement plus élevé, atteint un MAPE test de 3,4 % — une performance très nettement supérieure. Ce résultat illustre un enseignement méthodologique central : les critères d'information, optimisés en échantillon, ne garantissent pas la meilleure capacité prédictive hors-échantillon. Le modèle retenu s'écrit :

$$(1 - \Phi_1 B^{12})(1 - B)(1 - B^{12}) Y_t = (1 + \theta_1 B + \theta_2 B^2)(1 + \Theta_1 B^{12}) \varepsilon_t, \quad \varepsilon_t \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2) \quad (12)$$

Diagnostic des résidus




FIGURE 7 – Diagnostic des résidus du SARIMA retenu : résidus au cours du temps, distribution, QQ-plot et ACF.

Les quatre panneaux de la figure 7 valident l’adéquation du modèle. Les résidus ne présentent ni tendance ni hétéroscédasticité manifeste. L’histogramme et le QQ-plot confirment une distribution proche de la gaussienne. Enfin, l’ACF des résidus ne révèle aucune autocorrélation significative, ce qui atteste que le modèle a correctement extrait l’information temporelle disponible.

Prophet (Meta)

À titre de benchmark, l’algorithme Prophet est également testé. Ce dernier modélise la série sous la forme :

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t \quad (13)$$

où $g(t)$ désigne une tendance par morceaux, $s(t)$ une saisonnalité approximée par décomposition de Fourier :

$$s(t) = \sum_{n=1}^N \left(a_n \cos \frac{2\pi nt}{P} + b_n \sin \frac{2\pi nt}{P} \right) \quad (14)$$

et $h(t)$ un effet de jours fériés. Sur notre série, Prophet affiche un MAPE de 55,7 % — une performance décevante qui s’explique par le faible nombre de cycles saisonniers complets disponibles (88 observations mensuelles dont 25 interpolées). Ce modèle est écarté.

Residual Bootstrap et Bagging

Afin de réduire la variance d'estimation inhérente au Holt-Winters, on recourt à une procédure de bagging (*Bootstrap Aggregation*), introduite par Breiman (1996) et adaptée aux séries temporelles par Bergmeir et al. (2016). La démarche se décompose en six étapes :

Étape 1. Décomposition STL (*Seasonal-Trend decomposition using LOESS*) de la série d'entraînement. Contrairement aux moyennes mobiles, la STL estime la tendance par régression locale, ce qui évite la perte d'observations aux extrémités :

$$Y_t = \hat{T}_t^{\text{LOESS}} + \hat{S}_t + \hat{\varepsilon}_t \quad (15)$$

Étape 2. Récupération des résidus $\hat{\varepsilon}_t$ issus de la décomposition.

Étape 3. Génération de $B = 100$ échantillons bootstrap par tirage aléatoire avec remise sur les résidus. Le bootstrap classique est applicable ici, les résidus étant approximativement non auto-corrélés après décomposition STL robuste.

Étape 4. Reconstruction des séries bootstrapées en rajoutant aux résidus rééchantillonnés les composantes de tendance et de saisonnalité :

$$Y_t^{(b)} = \hat{T}_t^{\text{LOESS}} + \hat{S}_t + \varepsilon_t^{*(b)}, \quad b = 1, \dots, B \quad (16)$$

Étape 5. Estimation d'un modèle Holt-Winters additif sur chaque série bootstrapée $Y^{(b)}$ et production de prévisions $\hat{Y}_{T+h}^{(b)}$.

Étape 6. La prévision finale par bagging est la moyenne des prévisions individuelles :

$$\hat{Y}_{T+h}^{\text{bag}} = \frac{1}{B} \sum_{b=1}^B \hat{Y}_{T+h}^{(b)} \quad (17)$$

Les quantiles empiriques à 5 % et 95 % fournissent un intervalle de confiance à 90 %.




FIGURE 8 – Décomposition STL de la série interpolée complète : tendance estimée par LOESS, saisonnalité et résidus.




FIGURE 9 – À gauche : 10 séries bootstrapées superposées à la série originale. À droite : prévisions bagging avec IC 90 % sur la période de test.

Le bagging atteint un MAPE de 9,2 % sur le test, en légère amélioration par rapport au Holt-Winters simple (9,8 %). Ce gain, modeste mais systématique, confirme l'apport de l'agrégation

par réduction de la variance d'estimation.

Ensemble pondéré

Les deux meilleurs modèles — Holt-Winters additif et SARIMA — sont combinés par pondération inversement proportionnelle à leur MAPE de test :

$$w_{\text{HW}} = \frac{\text{MAPE}_{\text{SARIMA}}}{\text{MAPE}_{\text{HW}} + \text{MAPE}_{\text{SARIMA}}} = 0,26, \quad w_{\text{SAR}} = \frac{\text{MAPE}_{\text{HW}}}{\text{MAPE}_{\text{HW}} + \text{MAPE}_{\text{SARIMA}}} = 0,74 \quad (18)$$

$$\hat{Y}_{T+h}^{\text{ens}} = w_{\text{HW}} \cdot \hat{Y}_{T+h}^{\text{HW}} + w_{\text{SAR}} \cdot \hat{Y}_{T+h}^{\text{SARIMA}} \quad (19)$$

Le SARIMA, nettement plus performant sur le test, reçoit un poids prépondérant. Cette pondération constitue un compromis entre l'exploitation du meilleur modèle et la diversification du risque de suroptimisation sur un unique cadre méthodologique.

6. Comparaison des performances




FIGURE 10 – Prévisions hors-échantillon des modèles sur la période de test (juin 2023 – mai 2025).

Modèle	RMSE	MAPE	Décision
Décomposition polynomiale	1,740	95,2 %	Écarté
HW multiplicatif	0,439	21,0 %	Écarté
Prophet	0,987	55,7 %	Écarté
HW additif	0,208	9,8 %	Retenu
Bagging Bootstrap (HW)	0,171	9,2 %	Retenu
SARIMA(0, 1, 2)(1, 1, 1) ₁₂	0,090	3,4 %	Retenu
Ensemble pondéré (HW+SARIMA)	0,101	4,5 %	Prév. finale

TABLE 5 – Performance hors-échantillon des modèles (juin 2023 – mai 2025, $n = 24$).

Le classement hors-échantillon fait ressortir trois enseignements. Premièrement, le $\text{SARIMA}(0, 1, 2)(1, 1, 1)_{12}$ domine l'ensemble des modèles individuels avec un MAPE de 3,4 %, confirmant la pertinence d'une modélisation explicite de la structure d'autocorrélation. Deuxièmement, le bagging améliore marginalement le Holt-Winters simple (9,2 % contre 9,8 %), validant l'apport de la réduction de variance par agrégation bootstrap. Troisièmement, le schéma multiplicatif (MAPE 21,0 %) confirme son inadéquation déjà diagnostiquée lors de la décomposition.

L'ensemble pondéré (MAPE 4,5 %) est retenu comme prévision finale : il conjugue la précision du SARIMA et la robustesse du Holt-Winters, diversifiant ainsi le risque de modèle sur un horizon de 25 mois.

7. Prévisions finales : juin 2025 – juin 2027

Les modèles sont ré-estimés sur les 112 observations de la série complète interpolée afin de maximiser l'information disponible pour la projection.




FIGURE 11 – Prévisions finales juin 2025 – juin 2027. Les bandes indiquent les IC 90 % du SARIMA et du bootstrap. La courbe orange est la prévision retenue.

Année	Mois	SARIMA	HW	Bagging	Ensemble	IC 90 %
2025	Juin	1,681	1,690	1,646	1,683	[1,477 ; 1,885]
2025	Juillet	2,025	2,027	2,062	2,026	[1,782 ; 2,269]
2025	Août	1,815	1,838	1,748	1,821	[1,528 ; 2,102]
2025	Septembre	1,851	1,863	1,787	1,854	[1,526 ; 2,175]
2025	Octobre	2,017	2,009	1,883	2,015	[1,658 ; 2,375]
2025	Novembre	1,827	1,834	1,747	1,829	[1,438 ; 2,216]
2025	Décembre	1,938	1,948	1,850	1,941	[1,520 ; 2,356]
2026	Janvier	2,331	2,250	2,260	2,310	[1,887 ; 2,776]
2026	Février	1,926	1,909	1,865	1,921	[1,456 ; 2,395]
2026	Mars	1,797	1,825	1,775	1,804	[1,304 ; 2,290]
2026	Avril	1,837	1,840	1,787	1,838	[1,321 ; 2,353]
2026	Mai	1,744	1,743	1,681	1,744	[1,207 ; 2,282]
2026	Juin	1,762	1,765	1,692	1,763	[1,168 ; 2,356]
2026	Juillet	2,082	2,102	2,109	2,087	[1,450 ; 2,715]
2026	Août	1,895	1,913	1,794	1,900	[1,223 ; 2,568]
2026	Septembre	1,917	1,938	1,834	1,922	[1,208 ; 2,627]
2026	Octobre	2,066	2,084	1,929	2,071	[1,321 ; 2,811]
2026	Novembre	1,892	1,909	1,794	1,897	[1,114 ; 2,671]
2026	Décembre	1,992	2,023	1,897	2,000	[1,181 ; 2,803]
2027	Janvier	2,332	2,325	2,306	2,330	[1,490 ; 3,174]
2027	Février	1,967	1,984	1,912	1,971	[1,095 ; 2,839]
2027	Mars	1,859	1,900	1,822	1,869	[0,958 ; 2,759]
2027	Avril	1,886	1,915	1,834	1,894	[0,958 ; 2,815]
2027	Mai	1,797	1,818	1,728	1,802	[0,842 ; 2,751]
2027	Juin	1,814	1,841	1,739	1,821	[0,817 ; 2,811]

TABLE 6 – Prévisions mensuelles des arrivées de touristes (en millions).

Lecture des résultats

Tendance haussière confirmée. La dynamique de reprise post-pandémique se poursuit sur l'ensemble de l'horizon. Le volume projeté pour 2026 dépasse celui de 2025 d'environ 5 à 7 %, avec un pic attendu en janvier 2027 à 2,33 millions selon l'ensemble.

Saisonnalité structurellement préservée. Le profil mensuel reste centré sur les mêmes pics que ceux identifiés lors de la décomposition : janvier et juillet demeurent les mois les plus fréquentés, tandis que mai et mars marquent les creux saisonniers.

Incertitude croissante avec l'horizon. Les intervalles de confiance s'élargissent significativement à partir de mi-2026. À juin 2027, l'IC 90 % du SARIMA s'étend de 0,82 à 2,81 M. Les projections 2027 constituent dès lors des ordres de grandeur directionnels et doivent être interprétées avec la prudence qui s'impose.

8. Conclusion

Cette étude a conduit une démarche intégrée de prévision des flux touristiques sur vingt-cinq mois. Cinq enseignements se dégagent.

L'interpolation de la fenêtre pandémique conditionne l'ensemble de l'analyse : sans ce prétraitement, le MAPE de test atteint 95 %. Le choix du schéma additif, motivé dès la décomposition par la stabilité de l'amplitude saisonnière, se confirme en prévision, 9.8 % contre 21.0 % pour le multiplicatif. Le SARIMA(0, 1, 2)(1, 1, 1)₁₂, bien que mal classé par AIC, domine sur le test, avec un MAPE 3,4 %, rappelant que les critères d'information ne se substituent pas à la validation hors-échantillon. Le bagging réduit marginalement l'erreur du Holt-Winters (9,2 % contre 9,8 %), confirmant l'apport de l'agrégation bootstrap.

L'ensemble pondéré, avec un de MAPE 4,5 %, retenu pour la prévision finale, conjugue précision du SARIMA et robustesse du Holt-Winters. Les projections signalent une poursuite de la reprise touristique avec un profil saisonnier stable. L'intégration de variables exogènes dans un cadre SARIMAX constituerait une piste d'approfondissement naturelle.